Phụ lục 2 — Thống kê liên kết văn bản & tổng hợp phân tích đối chiếu EN–VI

Bộ dữ liệu: 20 cặp bài báo song ngữ Anh–Việt (Appendix 1) · 742 câu EN / 682 câu VI · 1.049 đơn vị liên kết (tie) phía EN và 892 tie phía VI, gán nhãn thủ công từng cặp.
Khung lý thuyết: phía EN — Halliday & Hasan (1976), *Cohesion in English* (quy chiếu R, thế S, tỉnh lược E, nối C, liên kết từ vựng L); phía VI — Trần Ngọc Thêm (1985; 2006), *Hệ thống liên kết văn bản tiếng Việt* (dẫn theo Nguyễn Thanh Tùng 2020), quy về cùng thang 5 danh mục. Trọng tâm nghiên cứu là **liên kết vượt câu (cohesion beyond the sentence level)**: các hạng mục R/C/L chỉ ghi ở cấp liên câu [LC]; S/E có thêm lớp bổ sung trong câu [TC] và **không** dùng làm bằng chứng cho kết luận về liên kết liên câu.
Kiểm soát chất lượng: mỗi cặp qua cổng QC cơ khí hai lượt (vị trí đánh dấu, occurrence, hướng tiền trạm, tái tạo văn bản gốc) và đối chiếu 10/10 ô giữa số đếm tay với tie table; 20/20 cặp PASS.

A. Thống kê tổng hợp

A.1. Toàn bộ 20 cặp

Danh mục	EN (số)	EN (%)	VI (số)	VI (%)	Chênh EN−VI
R — quy chiếu	279	26,6	215	24,1	+64
S — thế	11	1,0	4	0,4	+7
E — tỉnh lược	24	2,3	22	2,5	+2
C — nối	101	9,6	93	10,4	+8
L — từ vựng	634	60,4	558	62,6	+76
Tổng	**1.049**	100	**892**	100	**+157**
Số câu	742		682		+60
Mật độ (tie/câu)	1,41		1,31		

A.2. Mật độ từng cặp

Cặp	Câu EN	Câu VI	Tie EN	Tie VI	Mật độ EN	Mật độ VI	Ghi chú thể loại
P01	55	49	88	67	1,60	1,37	tin tính năng (SBS)
P02	47	51	67	67	1,43	1,31	tin tính năng, nhiều trích dẫn
P03	37	40	52	53	1,41	1,33	VI tự sinh 14 câu chuyển tiếp
P04	45	36	57	36	1,27	1,00	service journalism, VI cắt
P05	60	48	57	43	0,95	0,90	listicle thông báo
P06	38	24	30	15	0,79	0,63	VI cắt 15/38 câu
P07	73	73	95	92	1,30	1,26	feature giải thích, 73/73

							giữ 1–1
P08	40	38	76	70	1,90	1,84	listicle thống kê giá nhà
P09	40	37	61	53	1,53	1,43	chính sách – dữ liệu
P10	31	43	45	50	1,45	1,16	tài chính cá nhân, VI chèn 14 câu
P11	65	61	70	64	1,08	1,05	explainer nghi thức
P12	3	3	1	2	0,33	0,67	cặp micro (2 câu thật mỗi phía)
P13	13	8	20	8	1,54	1,00	tin ngắn, VI cắt khối 2018
P14	12	12	20	19	1,67	1,58	tin chính trị dày tên riêng
P15	34	29	57	38	1,68	1,31	VI cắt/viết lại (VOA); analysis P15 tính theo 31/26 câu thật (sau bỏ artifact) → 1,84/1,46
P16	18	18	30	29	1,67	1,61	tin du lịch Nga
P17	24	22	37	37	1,54	1,68	VI lặp tên attribution
P18	22	24	36	36	1,64	1,50	tin quyên góp từ thiện
P19	21	22	42	41	2,00	1,86	tin pháp lý, thuật ngữ dày nhất
P20	64	44	108	72	1,69	1,64	cặp cắt mạnh nhất (23 câu EN bị bỏ)

Mật độ dao động 0,33–2,00 tie/câu theo **thể loại và mức biên tập**, không theo độ dài: cao nhất ở tin pháp lý (P19), listicle thống kê (P08), chính sách dày thuật ngữ (P20); thấp nhất ở listicle thông báo khép kín từng mục (P05), cặp micro (P12) và explainer câu dài (P11). (Bảng dùng số câu cơ khí của bộ segment để nhất quán 20/20 cặp; một số analysis tính mật độ theo "câu thật" sau khi loại artifact — khác biệt có ghi chú riêng.)

A.3. Thành phần phụ từng danh mục

Quy chiếu (R) — 279 EN / 215 VI:

Tiểu loại	EN	(% R EN)	VI	(% R VI)
personal (đại từ nhân xưng)	158	56,6	97	45,1
demonstrative (chỉ từ/demonstrative)	102	36,6	105	48,8
comparative (so sánh)	19	6,8	13	6,0

Liên kết từ vựng (L) — 634 EN / 558 VI:

Tiểu loại	EN	(% L EN)	VI	(% L VI)
repetition (lặp)	508	80,1	477	85,5
synonym (đồng nghĩa)	82	12,9	53	9,5
antonym (trái nghĩa)	10	1,6	8	1,4
superordinate (thượng vị)	10	1,6	5	0,9
general word (từ tổng quát)	15	2,4	8	1,4
collocation (đóng đôi)	9	1,4	7	1,3

Nối (C) — 101 EN / 93 VI: additive 44/44 · adversative 37/38 · causal 10/4 · temporal 9/7 · continuative 1/0.

Thế (S) — 11 EN / 4 VI: EN nominal 8, verbal 3; VI nominal 1, verbal 2, clausal 1.

Tỉnh lược (E) — 24 EN / 22 VI: EN nominal 13, verbal 9, clausal 2; VI nominal 16, verbal 4, clausal 2.

A.4. Hướng quy chiếu và cấp liên kết

Chỉ số	EN	VI
Hồi quy A	255 (91,4% R)	201 (93,5% R)
Tiến chỉ C	2 (0,7%)	0
Ngoại văn bản E	22 (7,9%)	14 (6,5%)
Cấp [LC] (liên câu)	1.024 (97,6%)	876 (98,2%)
Cấp [TC] (trong câu — chỉ S/E)	25 (2,4%)	16 (1,8%)

B. Sáu phát hiện tổng hợp

B.1. Liên kết từ vựng là thiết bị chủ lực của cả hai ngôn ngữ — và VI còn "lặp" nhiều hơn EN

L chiếm 60,4% (EN) và 62,6% (VI) tổng số tie; trong nội bộ L, phép lặp chiếm 80,1% (EN) và **85,5% (VI)**. Đây là bằng nghị định lượng cho luận điểm của Trần Ngọc Thêm rằng *phép lặp* là thiết bị liên kết nền tảng của tiếng Việt: VI duy trì chuỗi bằng cách tái lập danh từ/tên riêng gần nguyên dạng, trong khi EN dễ **phân rã** sang biến thể đồng nghĩa hơn hẳn (synonym EN 82 ↔ VI 53; đối chiếu từng cặp: P13 chuỗi "Triều Tiên" EN 5 biến thể ↔ VI lặp tên; P17 VI hội tụ chuỗi đáy giá nơi EN phân rã). Hệ quả dịch thuật: bản VI thường **đậm từ vựng hơn bản EN ở đúng phần được dịch chung** (P05: L 29 VI ↔ 24 EN trên phần dịch; P09: 40 ↔ 40), dù tổng thể EN nhiều tie hơn vì VI cắt khối.

B.2. "Danh ngữ hóa quy chiếu" là dịch chuyển hệ thống EN → VI

Chênh R (279 ↔ 215) không nằm ở số lượng đại từ thuần: EN personal 158 (56,6% R) nhưng VI personal chỉ 97 (45,1%), trong khi VI demonstrative 105 (48,8%) cao hơn cả 绝对 số lẫn tỉ lệ dù tổng R ít hơn. Kết hợp đọc từng cặp, mô típ lặp lại nhất quán: **EN dùng đại từ/mạo từ thì VI dùng danh ngữ chỉ từ +

danh từ, hoặc lặp tên kèm danh xưng**:

- "It / This / The + N" (EN) → "Cuộc nghiên cứu này / Thỏa thuận này / Hệ

thống này" (P20, 18/18 cặp R đối ứng); "vụ kiện này, thời gian đó, việc này" (P19, VI 0 đại từ nhân xưng liên câu); "Hãng hàng giải này, tuyến bay này" (P06); "the analysis ↔ phân tích này", "the problem ↔ vấn đề này" (P02).

- Đại từ attribution EN "he said/she said" → VI "Ông X nói / Bà Y / Cô Z" —

honorific phân tầng theo nhân vật (P02: cô/bà/ông; P11: ông/bà đi kèm mọi lần lặp tên; P17: "he said" → "Ông Yium", khiến VI đậm hơn EN duy nhất ở cặp này). EN chỉ mã hóa she/he; VI mã hóa cả giới tính lẫn thứ bậc xã giao.

- Chiều ngược cũng có nhưng hiếm: VI dùng chỉ từ "này" nơi EN chỉ lặp mạo từ

(P02, P05) — tức cùng một vị trí, EN ghi L (lặp danh từ) còn VI ghi R (danh ngữ chỉ từ): hai ngôn ngữ phân công tính xác định theo hai đường.

B.3. Quy chiếu trong tin tức gần như toàn bộ hồi quy; ref=E mang dấu vết thể loại

Hướng A chiếm 91,4% (EN) và 93,5% (VI). ref=E (22 EN / 14 VI) hầu hết là đại từ ngôi 1/2 hướng độc giả — đặc trưng **service journalism**: P04 (we/you/here 5 hàng), P05 (we/you ↔ Bạn/bạn), P10 (you/bạn 3↔3, kể cả deck/headline gọi độc giả). ref=C chỉ 2 trường hợp (P08), đều do cấu trúc nguồn (dek đứng trước thân bài) chứ không phải tiến chỉ tu từ. Không có cặp nào ref=C phía VI.

B.4. Thế và tỉnh lược hiếm, gần như toàn bộ trong câu — không dùng làm bằng chứng liên câu

S (11/4) và E (24/22) cộng lại chỉ 3,3% (EN) và 2,9% (VI) tổng tie; 25/16 hàng [TC] đều thuộc S/E. Điểm đáng chú ý về mặt đối chiếu:

- **VI không ưa zero liên câu trong bộ liệu này**: các khe zero của VI tập

trung ở chủ ngữ vế tọa hợp trong câu; nhiều cặp VI lấp đầy toàn bộ khe tỉnh lược của EN (P01: E-EN = 0 vì VI lấp đầy). Ngược lại, VI có kiểu "đã phê chuẩn ∅" (P20, tân ngữ zero) mà EN hiện thực hóa "ratified it".

- Phép thế EN thường được VI **hiện thực hóa**: "don't" (E-EN) ↔ "làm vậy"

(S-VI) tại cùng vị trí P14 — bộ đối ứng chéo E↔S đẹp nhất của bộ; "do so" (P11, conf thấp) không có pro-form VI tương ứng.

- Chức năng "thế" của VI thường do **danh ngữ chỉ từ gánh** ("từ này", "điều

này" — P07, nơi S = 0 hai phía nhưng demonstrative dày), phù hợp nhận định của Trần Ngọc Thêm rằng tiếng Việt ít dùng pro-form thuần.

B.5. Nối gần đối xứng về số lượng và vị trí; chênh lệch nằm ở hai chiều hiện thực hóa

C 101 ↔ 93, additive và adversative gần như cân bằng tuyệt đối (44/44 và 37/38). Chênh causal (10 ↔ 4) phản ánh EN thích liên từ nhân–quả tường minh nơi VI diễn đạt bằng trật tự và ngữ nghĩa. Hai chiều dịch chuyển đều thấy:

EN ngầm → VI hiện thực (P04: 3 liên từ VI tự sinh "Nói cách khác/Tuy nhiên/ Ngoài ra" tại đúng 3 chỗ EN dùng thiết bị khác) và **EN tường minh → VI ngầm** (P18: "So" bị lược; P10: "in turn" và "So" bị lược). Trường hợp đổi hạng mục: "other steps" (R, EN) ↔ "cũng" (C, VI) ở P14 — minh họa nguyên tắc *function, not form* giữa hai khung.

B.6. Chênh lệch tổng EN–VI chủ yếu do biên tập (cắt/gộp/tự sinh), không do hệ thống ngôn ngữ

EN đậm hơn VI ở 18/20 cặp (+157 tie), nhưng phân tích từng cặp cho thấy phần lớn chênh lệch nằm ở **khối bị cắt**: P20 (23 câu EN bị bỏ, chứa 20/58 hàng L của EN), P06 (15/38 câu), P04, P05, P13, P15. Trên phần dịch chung, hai phía gần đối xứng (P09: L 40 ↔ 40). VI chỉ đậm hơn ở P17 (lặp tên attribution) và P12 (cặp micro). Ngược lại, VI **tự sinh** câu chuyển tiếp và lede ở P03 (14 câu), P10 (14 câu), P20 (lede 3 câu) — các câu này tạo tie VI độc lập, tiền trạm trong chính văn bản VI. Mọi so sánh cấp câu giữa hai phía vì vậy phải đi qua bản đồ câu của từng cặp (mục §1 trong 20 file phân tích).

C. Bất thường dữ liệu nguồn cần lưu ý khi dùng số liệu

Tổng hợp từ mục §8 của 20 file phân tích:

1. **P20 không có URL nguồn** trong file gốc (bất thường duy nhất về nguồn); một số cặp có hàng lede VI tự sinh không đối ứng EN (P20) hoặc hàng EN không đối ứng VI (P02 — dòng Wiradjuri).
2. **Câu artifact đã loại khỏi đánh dấu**: caption pull-quote, câu lặp nguyên văn (P01, P07 S056, P10), chú thích biên tập (P07 S071), hàng "(1)/(?)" (P15, 5 hàng) — không dùng làm bằng chứng cấp câu.
3. **Lỗi nguồn hai phía**: typo EN ("outh Korea" P13, "Australia English" P07, "The fisherman have" P20), typo VI ("đối phó vơi" P11, "chắc chắc" P20), thiếu dấu cách (P07 S024/S055, P20 S003/S039), "IIU" thay "IUU" *ở* **cả hai phía** P20; một số bản dịch sai nghĩa (P07 S022 "làm tăng độ tin cậy" — ngược nghĩa gốc).
4. **Segmenter chẻ câu tại dấu viết tắt/điểm dừng bất thường** (Mr., Jr., U.S., dấu "”" tách rời P11 S051): các quyết định [LC]/[TC] và "câu kề" đã tính lại theo câu thật theo quy ước phiên, có ghi chú trong từng analysis.

D. Hạn chế của phiên phân tích

- Số đếm phụ thuộc **chính sách đánh dấu L của phiên** (chuỗi hẹp theo tổ hợp từ đa tiết; đánh dấu biến thể mới/tái lập sau khoảng cách ≥ 2 câu; không đánh dấu lặp kề) — các nghiên cứu khác dùng chính sách khác sẽ ra số khác; cần trích kèm quy ước khi so sánh.

- Phân tích manual-first một luồng, mỗi hàng có conf (high/med/low) và alt

(phương án mã khác đã cân nhắc); các hàng bridging/conf thấp đã ghi rõ.

- Lớp [TC] (41 hàng toàn bộ) chỉ mang tính bổ sung mô tả, không kết luận được

gì về liên kết liên câu.

- 20 cặp đều là tin tức/báo chí Úc–Việt hiện đại; kết luận không nên ngoại suy

sang thể loại tự sự dài, học thuật hay văn học.

Báo cáo này được tổng hợp từ 20 file phân tích chi tiết (`work/analysis/P01–P20_semantic.md`, mỗi file 9 mục) và số liệu tie đã qua cổng QC của pipeline; số liệu thô tại `out/appendix2/appendix2_stats.json` và `out/appendix1/match_stats.json`.